ML – это в общем виде

L - loss func, сделать min из него

L loss → min $\theta = \underset{\theta}{\arg\min}\ L(x, \theta)$

θ – параметр, хар-ки которых можно изменять и получить значение рез-л

X – данные для обучения

Все – веса нейросети, на что надо умножить входные данные

параметр – то, что можно контролировать, чтобы она нужно выглядело

argmax – нужно – θ сделать

3 задачи ML: (просто всё в кучу)

1) Регрессия – предсказывает X → число

$$f \mid X \to \mathbb{R}^n \mid$$

2) Классификация   тут есть количество классов

$f \mid X \to C \subseteq N \mid$

3) Кластеризация   тут нет изначальных классов

$f \mid X \to C \subseteq N \mid$

4) Ранжирование м-во, надо его упорядочить типа сортировка по сложной схеме

5) Снижение размерности (не совсем задача ML, но пойдёт)

$n \times n \rightarrow n \times (n-m)$ при этом расположение между векторами должно быть таким же, то есть без потерь

Расстояние Кульбака-Лейблера, метрика чтобы сравнить похожесть распределение, это тоже loss

6) RL — reinforcent learning, обучение с подкреплением, типа премию давать за хорошие действия

тут нет loss ф-ии, поэтому даём премию набивать score по странной ф-ии

7) Генерация текста (это классификация)
/звука/ картинка

8) Генерация звука

9) Speach recognishion

10) Detection — нахождение объекта, где

11) Segmentation — определение класса каждого пикселя

13) Embeddings

Embed — встроить, вместить, вставить объект в векторное пр-во

Функции снижения размерность:
из картинки → в вектор

14) Временной ряд

Мера м-ва где не выполняется = 0

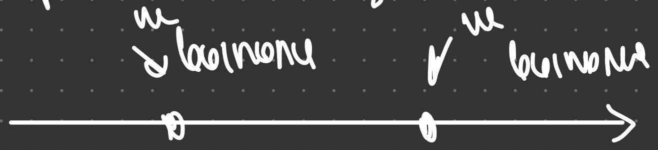

если эти точки далеко → то почти выполняется

если эти точки равны или близко, то не выполняется

$$\theta = \arg\min_{\theta} L(x, \theta)$$

$$L \mid X \times \Theta \to \mathbb{R}$$

функция, которая отображает пары из X и Θ в $\mathbb{R}$

Есть метод оптимизации Байесовская оптимизация

Градиентный спуск

Почему градиент — потому что точка min, max, перегиб — $L'_\theta(x, \theta) = 0$ в этих точках

" ф-ции + → но это min
вектор частных производных

$$\nabla L \text{ (градиент)} = \left(\frac{\partial L}{\partial \theta}, \frac{\partial L}{\partial \theta_2}, \dots, \dots \right)$$

указывает в сторону max роста ф-ции

Если мы пойдём в сторону роста, то найдём max, min наоборот

$\theta_{t+1} = \theta_t - \alpha \nabla_\theta L$ – learning rate – размер шага

Маленький шаг, чтобы уменьшить его нужны алгосы разные для этого

Прогрев – это когда градиенты сначала по большие шаги, чтобы найти хотя бы какой-то рез-> потом

Производная – скорость роста ф-ции в точке

$$\frac{dF}{dx} = \lim_{\Delta x \to 0} \frac{F(x+\Delta x) - F(x)}{\Delta x}$$

Частная пр-я – по переменной

$$\frac{\partial F}{\partial x} = \lim_{\Delta x \to 0} \frac{F(x+\Delta x, y) - F(x, y)}{\Delta x}$$

y – const

если $y = 0$, то $\frac{dF}{dx} = 0$

Оценка производной —

1) Разностная схема изменения пр-и

$$\frac{F(x+\Delta x) - F(x)}{\Delta x}$$

смещаем в Δx, во ли x, разность и смотрим на р-т разности

$$g \in O(F) \rightarrow \lim_{n \to \infty} \frac{g(n)}{F(n)} = c$$

если g растёт быстрее, то

если g медленнее, то $=0$

$n \in O(n)$

$2n \in O(n)$ т.к. $\lim \frac{2n}{n} = 2$

$$F'(x) = \frac{F(x+\Delta x) - F(x)}{\Delta x} + o(\Delta x)$$

Разностный подход оценки пр-ой

$o(\Delta x)$ — значит $=0$, значит ... ?

о малое

о малое — должна меньше быть
О большое - похожие ф-ии

Нужно чтобы оценить то, насколько ошибка

возможно ф-ии чуть другие

Есть методы 2-го порядка для ошибки

$$\frac{f(x+2\Delta x) - 2f(x+\Delta x) + f(x)}{2\Delta x} + O(\Delta x^2)$$

используем 3 точки а не 2

Можно добавить ещё точки, т.к это уменьшает ошибку

1) $x' = 1$

2) $(a\,x)' = a$ $\qquad x^{\frac{1}{n}} = \frac{1}{n} \cdot 1$

3) $(x^n)' = n \cdot x^{n-1}$

4) $(a^x)' = a^x \cdot \log a$

5) $\sqrt[n]{x} = \frac{1}{n\sqrt{x}}$

6) $(e^{x}') = e^x$

7) $(\ln x)' = \frac{1}{x}$

8) $(\log_b a) = \frac{\log_c (a)}{\log_c (b)}$ все log отличаются на конст, но, натуральные все log

$$\left(f(x)\,g(x)\right)' = f'(x)\,g(x) + f(x)$$

$$\left(\frac{f(x)}{g(x)}\right)' = \frac{f'(x)\,g(x) - f(x)\,g'(x)}{g^2(x)}$$

$(f(g(x))') =$ внеш. · внутр $= f'(g) \cdot g'(x)$
сложной ф-ии (chain rule)

2 пара:

оценка 1-й пр-ой (порядок)

$$-\frac{F(x + 2\overset{h}{\Delta x}) + 4F(x + \overset{h}{\Delta x}) - 3F(x)}{2h} + O(h^2)$$

оценка 2-й пр-ой 1 порядок

$$\frac{F(x+2h) - 2F(x+h) + F(x)}{h^2} + O(h)$$

как получить

$$F(x) = \frac{f(x+h) - f(x)}{}$$

как из 1-й получить вторую

$$\frac{\dfrac{F(x+2h) - F(x+h)}{h} - \dfrac{F(x+h) - F(x)}{h}}{h} =$$

Град. спуск:

$$\theta_{t+1} = \theta_t - \gamma \frac{dL}{d\theta}$$

Проблема алгоритма:

1)

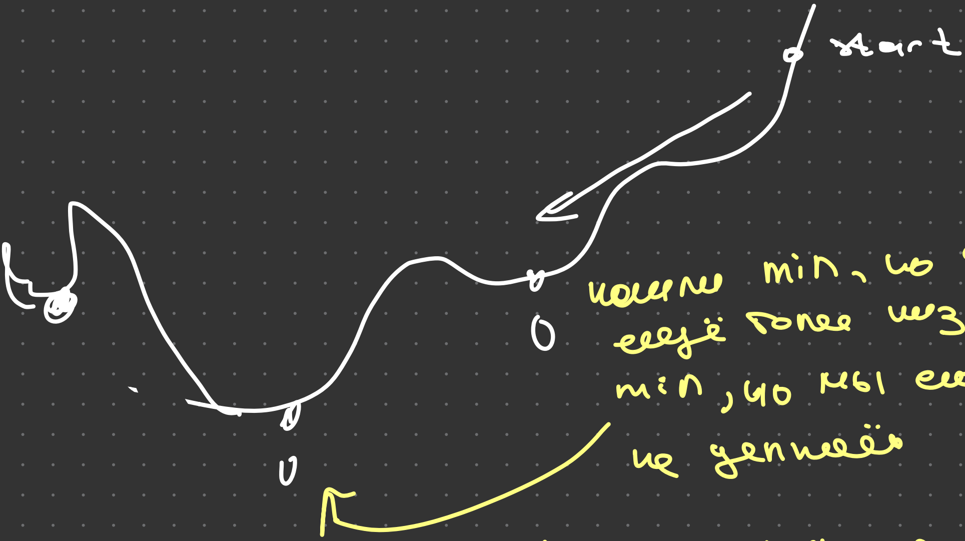

локальн min, но есть ещё более низкий min, но мы его не дойдём

перескочить путём ↑ шага нельзя, т.к. можно перескочить min

Есть градиент с моментом

$$\theta_{t+1} = \theta_t - \gamma g_t$$

g_t = град. на пред шаге

$$S_t = \alpha g_{t-1} - \gamma \frac{dL}{d\theta}$$

$\alpha \in [0, 1]$

Здесь мы сохраняем импульс прошлого шага и разгоняемся

Если сила будет недостаточно высокой, то мы перескочим, если нет, то нам не повезло

α надо выбирать с умом каталось плохо и в обратную сторону, можно сохранять min, но на больших нейронках это тяжело

Алгоритм Нестерова есть и защищает от того чтобы

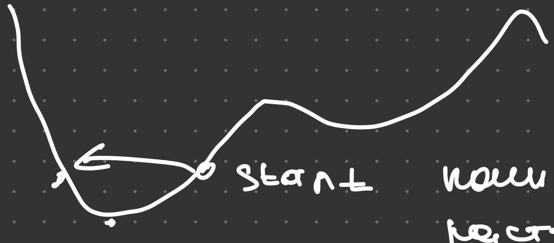

наш шар и так быстро растёт и защищает от маятника

Nesterov ∂ - LR

$$\theta_{t+1} = \tilde{\theta}_t + g_t$$

$$g_t = \alpha g_{t-1} - \partial \frac{\partial L}{\partial \theta}\Big|_{\theta = \theta_t + g_{t-1}}$$

то есть точка расчёта
она берётся следующей,
мы заглядываем типо в будущее, это пони-
жает риск попасть в неправильную точку

это решение проблем когда мы застреваем
в локальном минимуме

Есть ещё проблемы другие:

1) Единицы измерения
θ - может быть что угодно
некоторые могут иметь большую пр-ю,
некоторые маленькие

1) Алгос Ada grad
тут нет LR

$$\theta_{t+1} = \theta_t - \frac{\frac{\partial L}{\partial t}}{\sqrt{G^2_t + \varepsilon}}$$

+ε – чтобы не делить на 0, мал. зн-е

$$G^2_t = G^2_{t-1} + \lambda\left(\frac{\partial L}{\partial t}\right)^2$$

Проблема в том, что алгоритм сходится, то есть $G \to \infty$

Зачем делить на сумму кв. произв?

Нужно нормирование

Корни кв. производных, у маленьких у них напр. большие имеют больше и в итого мы идём с одной σ по всем измерениям

но алгоритм всегда останавливается,
конец нужно чтобы шёл до конца

2) RMS Prop, тут есть LR

$$\theta_{t+1} = \theta_t - \frac{\alpha \frac{\partial L}{\partial \theta}}{\sqrt{G_t^2 + \varepsilon_2}}$$

$$G_t^2 = \alpha G_{t-1}^2 + (1-\alpha)\left(\frac{\partial L^2}{\partial \theta_t}\right)^2$$

затухание

хорошо сходится + есть нормирование

Решено 2 пр-бы:

1) Можно выйти из ямы

2) нормир, т.к у больших зн-й рост больше, а у мелких меньше, → уровнять

Делаем шаги в долях и нормирование

Можно все алгоритмы объединить

Adam

Adaptive moment

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)\frac{\partial L}{\partial \theta_t}$$

$$S_t = \beta_2 g_{t-1} + (1-\beta_2)\left(\frac{\partial L}{\partial \theta}\right)^2$$

$$\theta_t = \theta_{t-1} - \alpha \frac{\tilde{m}_t}{\sqrt{\tilde{g}_t + \varepsilon}}$$

β_1, β_2 – гипер парам

т.к. алгос долго разгоняется, ..то

$$\tilde{m} = \frac{m}{1-\beta_1^{t}}$$

$$\tilde{g}_t = \frac{g_t}{1-\beta_2^t}$$

просто в начале делаем числа больше

Проблем в град. спуске много, но мы хотим решить пока только 2 проблемы

β_1 и β_2 независимые и не связанные

$$g_t = \beta_2^2 g_{t-2} + \beta_2 (1-\beta_2)\left(\frac{\partial L}{\partial \theta_{t-1}}\right)^2$$

$$+ (1-\beta_2)\left(\frac{\partial t}{\partial \theta}\right)^2$$

pd

data.describe()

(-1,0) (0,-1) (1,0) (0,1)

data["Pclass"]

индекс — это уникальный идентиф строки

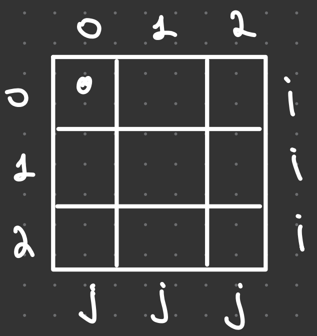

cols=3

rows=3

$$\begin{cases} i+j > rows = 0 \\ i+j < 0 = rows \\ \text{else } i+j \end{cases}$$

5 пунктов обучения с учителем отличающиеся выдаваемым значением

$y - R$ (0.003) выход модели

$y = R^M$ (0,01, 0,02 ... m)

Регрессия (линейная частный случай) — это просто предсказание вещественного числа

Iris dataset

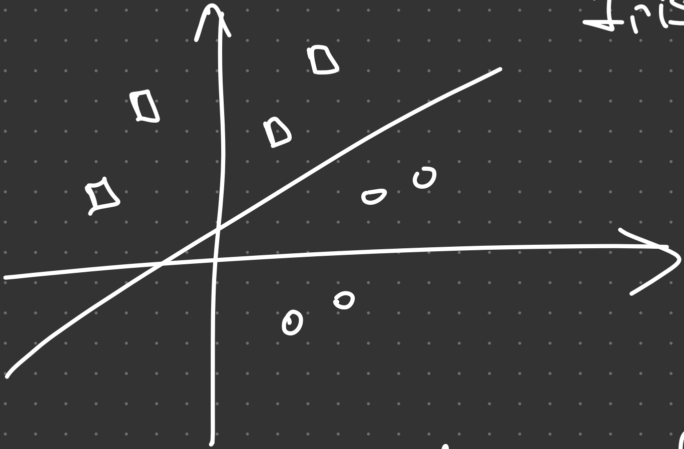

recall – хотим всех охватить

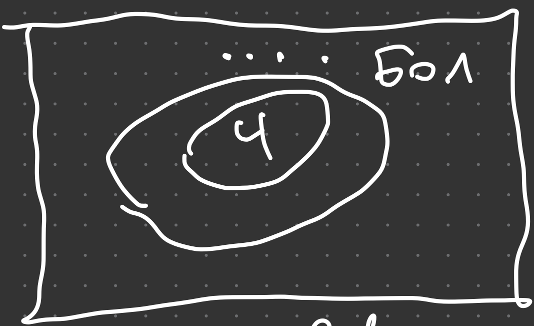

Recall>>

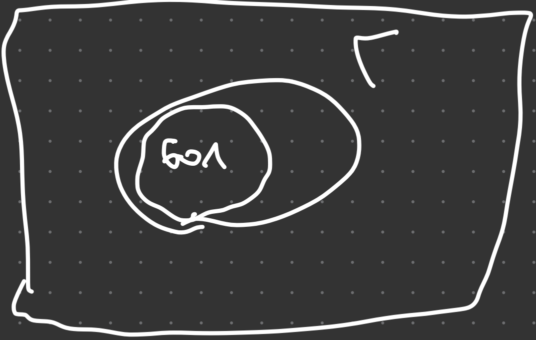

Precision>>

$$\text{accuraci} = \frac{\text{правильное}}{\text{все}}$$

$$\frac{\text{правильно}}{\text{все больные}}$$

$x \subseteq \mathbb{R}^n$ $y = wx + b = \sum_{i=1}^{n} w_i x_i + b$

$y \subseteq \mathbb{R}$ $w \subseteq \mathbb{R}^2$ лин. рег.

$b \subseteq \mathbb{R}$

$$\sum_{i=1}^{n} w_i x_i^2 + b = \sum_{i=1}^{n} w_i z_i + b$$

↑ парабола   ↑ замена

$x \in \mathbb{R}$ − 1 x $x \subseteq \mathbb{R}$ − много x

$y = \underset{\subseteq \mathbb{R}^{n+1}}{w} \cdot x + b$ $\mathbb{R}^{n+1}$ избавиться от x

$$\underset{}{\overset{\subseteq \mathbb{R}^{n+1}}{[w, b]}} \cdot \overset{\subseteq}{[x, 1]} = \tilde{w} \cdot \breve{x}$$

$w_1 \cdot x_1 + w_2 \cdot x_n + \ldots + b \cdot 1$ теперь биаса нет

$+ b \ldots$

$y = w \cdot x\ [+b]$ и в конце добавить переменную

$$\underset{\text{MSE}}{L(y,\hat y)} = \frac{1}{n}\sum_{i=1}^{m}(y_i-\hat y_i)^2 = \frac{1}{|y|}\|y-\hat y\|_2^2$$

норма вектора x

не модуль а потому что в нуле не дифференцируема

$$\|x\|_p = \sqrt[p]{\sum_{i=1}^{|x|}|x_i|^p} \qquad l_p$$

евклидово, манхетонское расстояние

Свойства нормы: lp-пространство по норме

Lp-пространство в котором нормированы ф-ии

1) по

$$\|f\|_p = \sqrt[p]{\int_{-\infty}^{\infty}|f(x)|^p\,dx}$$

$$\|x\|_1 \geq \|x\|_2 \ \ldots \geq \|x\|_n$$

$\|x\|_\infty = \max(|x|)$ → самое большое

бесконечность

$\|x\|_{0,5}$ → норма может быть не целой

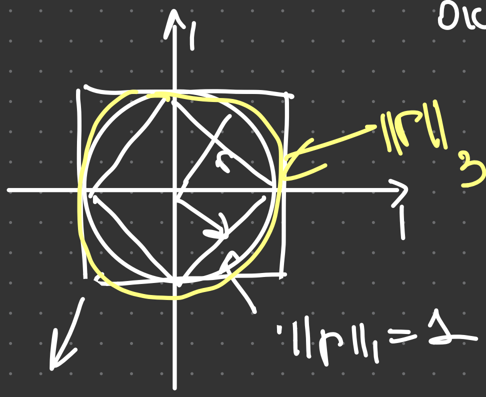

Окружность по норме r

1 норма - ромб

3 Выпуклость в квадрат

<1 - ромбы впуклые внутрь

$\|r\|_2$

В ML нужны нормы 1,2 и оч. редко ∞.

Норма значит длину вектора

l_1 => манхэттенское р-е

l_2 => евклидова норма

Норма разницы $y - \hat{y}$ = MSE

MAE

⇓

absolute

mean squared error

root mse → корень

теперь надо улучшать ошибку

$$\frac{1}{|y|}\sum_{i=1}^{|y|}\left(y_i-(wx_i-b)\right)^2$$

$y_i \in \mathbb{R}^n$ $\quad w \in \mathbb{R}^n$

$x_i \in \mathbb{R}^n$

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial b} = \text{считаем}$$

$$\frac{\partial L}{\partial b} = \frac{1}{2|y|}\sum_{i=1}^{|y|} 2\cdot(y_i-w\cdot x-b)\cdot(-1)$$

можно 2 подставить

$$\frac{\partial L}{\partial w_j} = \frac{2}{|y|}\sum_{i=1}^{|y|}(y-wx_i-b) - w_1x_1 - w_2x_2 - \dots - w_jx_j$$

↑ по 1 значению берём $\quad = -x_j$

$$\frac{2}{|y|}\sum_{i=1}^{|y|}(y-wx_i-b)\cdot(-x_j)$$

$$\frac{\partial L}{\partial W} = -\frac{2}{|y|}\sum_{i=1}^{|y|}(y_i - w x_i - b)\cdot x_{ij}$$

x_i – строка, x_{ij} – эл-т

Дальше можно применить градиентный бустинг

Аналитическое решение

$L = \|Y - W\cdot X - b\|_2$ надо избавиться от нормы

Надо понять, что такое $\|x - y\|_2 = \sum_{i=1}^{n}(x_i - y_i)^2 \Rightarrow$

$$(x_i)^2 - (y_n)^2 = \sum_{i=1}^{n} x_i^2 - 2xy + y_i^2 \Rightarrow$$

$$= (Y - XW)^T (Y - XW) = Y^T \cdot Y -$$

$$(m,n)\cdot(n,) - (m,) \Rightarrow$$

$$(1,m)$$

$$(1,n)^T \cdot (n,m)^T$$

$$(AB)^T = B^T A^T$$

$$= Y^T Y - Y^T X W - W^T X^T Y + W^T X^T X W$$

$$W^T X^T Y = Y^T X W$$

$d = 0$ $\quad$ $d = -y^T X$ $\quad$ $d = -Y^T X$

$$= Y^T Y - \overline{2Y^T} X W + (W^T X^T X W$$

$d = y^T w$ $\quad$ и $\quad$ $2X^T X W$

loss дифференцируем

пропустила случайно

$$\frac{d(\ \ldots\ )}{dw}$$

$w \cdot x_i$

матричное дифференцирование посчитать

$(1,n) \cdot (n,m) \Rightarrow (1,m)$

потом

$(1,m) \cdot (m,n) = (1,n) \cdot (n) \Rightarrow (1)$

производная $\Rightarrow$

$-2Y^T X + 2X^T X W = 0$ потому-что потому что если это min то производная $= 0$

$X^T X W = Y^T X \ |: X^T X$

$$\frac{x}{y} = x \cdot y^{-1}$$

$$\Rightarrow \Big(\underbrace{(x^Tx)^{-1} x^T \Big) x}_{\begin{pmatrix} 1 & \\ & 1 \end{pmatrix}} W = (x^Tx)^{-1}$$

единичная матрица

$$\Rightarrow W = (X^TX)^{-1} X^T Y$$ это и есть аналитическое решение

если матрица не имеет обратной, если все столбцы линейно зависимые то решение не работает т.к. не будет единичной матрицы

Ищем такие w, при которых функция минимальная

чтобы найти и понять что это min нужно взять вторую производную, то ...

Если матрица полож → то это min, положит определена → вектор не меняется в итоге значит она положительно определена

Седловой точки у такой матрицы нет

Если вторая пр-я равна 0, то ∇ равна F не меняется

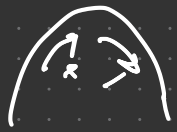

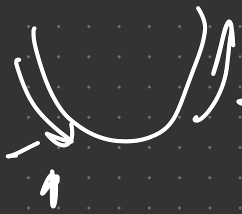

+ f умножилась на + число

умножение на − число

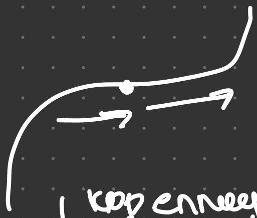

d корреляция

$$\mathrm{corr}(x,y) = \frac{n\cdot\Sigma x\cdot y - \Sigma x\cdot\Sigma y}{\sqrt{n\Sigma x^2\ (\Sigma x)^2}\sqrt{n\Sigma x^2 - (\Sigma x)^2}} =$$

$$\frac{\frac{1}{n}(x-\bar{x})(y-\bar{y})}{\|x\|_2\,\|y\|_2}$$

надо поделить на норму векторов

Метрики:

R^2 коэффициент детерминации =>

$$1 - \frac{mse(y,\hat{y}) \in \infty}{mse(y,\bar{y}) \in \infty}$$

сколько колебаний модель объясняет

ограничены нулём

$R^2 \in [-\infty;\ ;1]$

$\hat{y} = wx + b$

=1 средние

>0 лучше среднего

<0 хуже среднего

Момент из распределения, статистика

Это характеристика

Есть функция производящая моменты

Хорошо посчитать

Анскомб – придумал квартет

У этих групп абсолютно одинаковые метрики ср, D, и другие дисперсия

(говорит, как оно всё ведёт, а не как выглядит

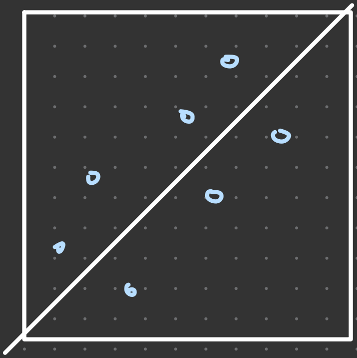

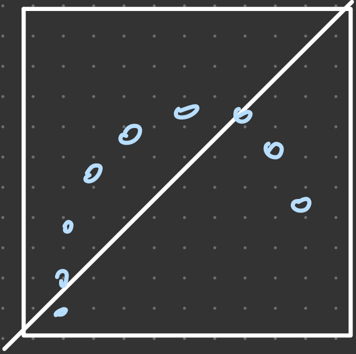

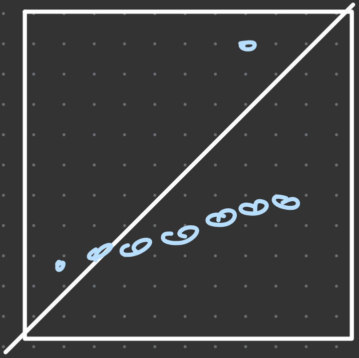

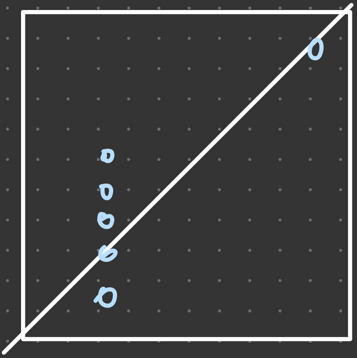

То есть графически не всегда понятно что за распределение

Гомоскедентичность

дисперсии ошибок
примерно одинаковы

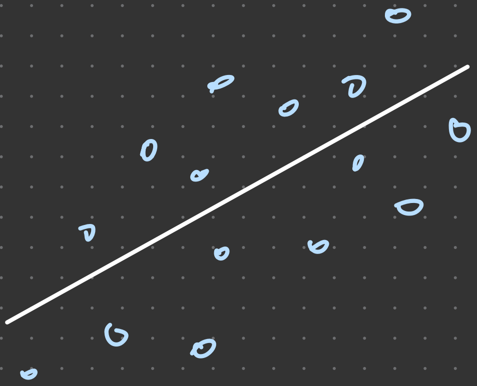

Гетероскедантичность

тут нельзя
применить
линейную
регрессию

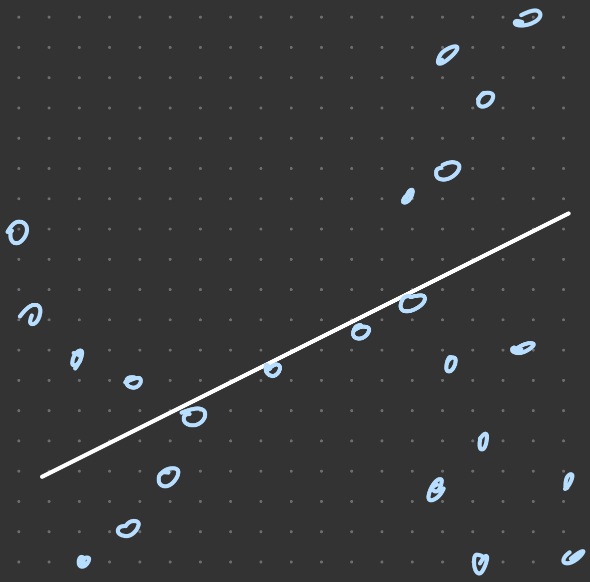

Регуляризация

Если у модели есть переобучение, то нужно чтобы модель перестала выдавать очень большие коэффициенты

$$L(y,\hat{y}) = MSE(y,\hat{y})$$

где $\hat{y} = x \cdot W$

надо что-то добавить в loss, чтобы слишком не запоминать его

$$L(y,\hat{y}) = MSE(y,\hat{y}) + \|W\|_1 \alpha$$

сумма модулей

lasso $y = w \cdot x \cdot \alpha \|w\|_1$

Ridge $\Rightarrow y = w \cdot x \cdot \alpha \|W\|_2$

Elastic $y = \dots \alpha \|w\|_2 + \lambda \|w\|_1$

lasso имеет свойства:

1) при ↑ α lasso постепенно зануляет коэф. w

нужно нарисовать

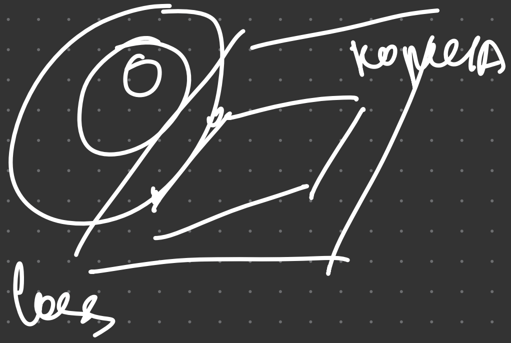

lasso позволяет избавляться от ненужных признаков

Линейная регрессия хорошо интерпретируема

Помним 10 объектов, надо найти 11 → можно попробовать решить зада-
тоже
чу

31.10.2026 Лог. регрессия

$X \in \mathbb{R}^n$ $k = \overline{0, K-1}$ $\in N^T$

$|K| < \infty$

мощность $< \infty$

$F | X \to X$

классы взаимоисключающие

$F(x, \theta) = \theta x \in \mathbb{R}$

сигмоида - ф-ия, похожая на sin

$$\text{sigmoid}(x) = \frac{1}{1+e^{-x}}$$

↑

это вид сигмоида

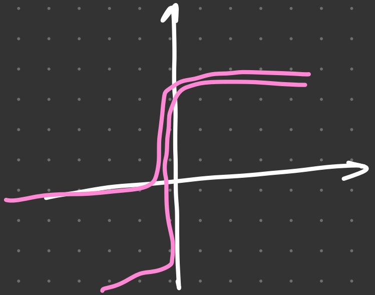

Функция норм. распределения → это сигмоида тоже

$\Phi(a) = P(x < a)$ $x \sim N(0,1)$

х примерно похоже на норм р-е

Что такое плотность норм. распределения ?

1) Сделать сигму

$\text{sigmoid}(F(x, \theta)) \in [0, 1]$

нужно одновременно разбить на интервалы и определить θ

$\sim P(x = K_1)$ вероятность того что

вероятность положительного класса

$$\begin{cases} 0, & p < 0{,}5 \\ 1, & p \geq 0{,}5 \end{cases}$$

$x \sim N(0,1)$ $P(x=0.5)=0$ Вспомнить статистику

$$P(X \in [0{,}4; 0{,}6]) = \Phi(0{,}6) - \Phi(0{,}4) = \int_{0{,}4}^{0{,}6} F(x)\,dx$$

ф-ия плотности

Можно попробовать без сигмоиды

Есть пороговая ф-ия (ступенчатая) t - порог

$\exists\, t=0$, как её обучать

$$\begin{cases} 0, & F < t \\ 1, & F \geq t \end{cases}$$

Если $t \,!\!= 0$, то нужно её сдвинуть $F(x,\theta) = \overset{\in R}{\theta_x} - t$

$$\begin{cases} 0, & F < 0 \\ 1, & F \geq 0 \end{cases}$$

Р-е Бернулли → может предсказать только 2 зн-ия 1 или 0

$$F(x,\theta) = \theta_x = \underbrace{\log\left(\underbrace{\frac{p}{1-p}}_{\text{шанс}}\right)}_{\text{логит}}$$

нужно понять как это обучать

$\theta_x = \log\left(\frac{p}{1-p}\right)$ => ф-ия обратного log =>

нужно получить p

$$e^{\theta_x} = \frac{p}{1-p} \quad \Big|\cdot 1-p$$

$$e^{\theta x}(1-p) = p$$

$$e^{\theta x} - pe^{\theta x} = p$$

$$e^{\theta x} = p + p\cdot e^{\theta x}$$

$$e^{\theta x} = p\cdot(1+e^{\theta x})$$

$$p = \frac{e^{\theta x}}{1+e^{\theta x}} = \frac{1}{\frac{1}{e^{\theta x}}+1} = \frac{1}{1+e^{-\theta x}}$$ логистическая сигмоида

$\Rightarrow p = \text{sigmoid}(\theta x)$ 1- у сигмоиды)

когда видим сигмоиды мы подразумеваем логистич. сигмоиду

нужно придумать loss - ф-ию

нужно научиться как-то справляться с классами

$k \in \{0;1\}$

$$p = P(\overset{y_1}{k_0} \mid x)$$

$$1-p = P(\overset{y_0}{k_0} \mid x)$$

мы хотим 2 ф-лы объединить в одну

$$P(y=k \mid x) = p^{k}(1-p)^{1-k}$$

если $k=0$ $\Rightarrow$ ф-ия говорит

если $k=2$ насколько вероятно

то что наш объект

принадлежит классу

для идеальной модели $k=1$

=> ф-цию нужно максимизировать => антиградиент

$L(k,p) = -p^k (1-p)^{1-k}$ в степени p возводить неудобно

=> логарифмируем, логарифм монотонно возрастающая => min, max не изменятся

$\log(p^k) + \log((1-p)^{1-k})$

$k\log(p) + k\log(1-p)$

обычно y пишут

$-(y\log(p) + (1-y)\log(1-p))$

лог. лосс
бинарная кросс энтропия

$p = \text{sigmoid}(\theta x)$ => просто замена

$1 - \text{sigm}(x) = \text{sigm}(-x)$

хорошо не надо больше ничего запоминать

нужно найти производную для loss
$p = \sigma(\theta x)$ σ-сигмоида

$$\frac{\partial L}{\partial \theta} = \frac{y}{p} \cdot \sigma(\theta x)' - \frac{1-y}{(1-p)} \cdot \sigma(\theta x)'$$

$$= \sigma(\theta x)' \left(\frac{y}{p} - \frac{1-y}{1-p}\right) \cdot$$

Посчитаем производную сигмоиды

$$\left(\frac{1}{1+e^{-\theta x}}\right)' = \left((1+e^{-\theta x})^{-1}\right)'_\theta = -1\cdot(1-e^{-\theta x})^{-2} \cdot$$

$$(e^{-\theta x})'_\theta = (1+e^{-\theta x})^{-2} \quad e^{-\theta x}\cdot x$$

это итоговая пр-ая

Чего нужно опасаться в этой штуке, то мб быть деление на 0

можно ε добавить

был $y \in \{0;1\}$ будет $y \in \{-1;1\}$

$y\log p + (1-y)\log(1-p)$ это для $\{0;1\}$

нужно менять коэф

$y = \frac{y+1}{2}$ замена $\quad 1 + \frac{1+y}{2} = \frac{2-1-y}{2} = \frac{1-y}{2}$

$$\frac{1+y}{2}\log(p) + \frac{1-y}{2}\log(1-p)$$

нужно ввести упрощение

$\log(P) = \log(\sigma(\theta x))$ $\quad \sigma = \log\left(\frac{1}{1+e^{-\theta x}}\right)$

можно написать log частного

$$\frac{1+y}{2}\Big(\underset{\overset{\|}{0}}{\log(1)} - \log(1+e^{-\theta x})\Big) + \frac{1-y}{2}\Big(\log(1) - \log(1+e^{\theta x})\Big)$$

$\log(1) + e^{-\theta x} - y\log(1+$

$$\begin{cases}\log(1+e^{\theta x}), & y=-1\\ \log(1+e^{-\theta x}), & y=1\end{cases} \Rightarrow -\lg(1+e^{-y\theta x})$$

то есть если подставить y в виде системы, то loss получается в одно выражение

теперь пр-ая

$$\log(1+e^{-y\theta x})'_{\theta} = \frac{-yx}{1+e^{-y\theta x}}\cdot e^{-y\theta x} = -yx\frac{1}{1+e^{y\theta x}} =$$

$$\boxed{= -yx\cdot\sigma(y\theta x)}$$

это для бинарной классификации

$\theta x = \log\left(\frac{p}{p-1}\right)$ к- какой-то класс

$\theta_i x = \log\left(\frac{p_i}{p_k}\right)$; $i=\overline{1,k-1}$ Считаем все классы против 1

$p_0 + p_1 = 1$

$p_0 = 1 - p_1$

$\sum p_i = 1$ $\quad p_i = 1 - \sum_{j \neq i} p_j$ но это неудобно и удобнее против 1 класса

$\Big\downarrow e$

~~Px~~

$e^{\theta_i x} = \frac{p_i}{p_x}$ $\quad p_i = e^{\theta_i x} \cdot p_k$

$\sum_{i=1}^{k} p_i = 1$ нужно сделать $= 1$

$\uparrow$

Включая a_k

$p_k = 1 - \sum_{i \neq k} e^{\theta_i x} p_k$

$p_k = 1 - p_k \sum_{i=k} e^{\theta_i x}$

$p_i + p_k \sum e^{\theta_i x} = 1$

$$\boxed{p_k = \frac{1}{1 + \sum_{i \neq k} e^{\theta_i x}}}$$

$$\Rightarrow p_i = \frac{e^{\theta_i x}}{1 + \sum\limits_{i \neq K} e^{\theta_i x}}$$

K-1 линейных регрессий для всех классов

так обычно не делают

Есть вариант #2 → softmax

$$\theta_x = \log\left(\frac{p_i}{p_K}\right) = \log(p_i) - \log(p_K)$$

теперь Z = какая-то константа

$$\theta_x = \log\left(\frac{p_i}{p_K}\right) = \log(p_i) - \log(Z)$$

$$e^{\theta_i x} = e^{\log(p_i) - \log(Z)} = \frac{e^{\log p_i}}{e^{\log Z}} = \frac{p_i}{Z}$$

$$p_i = Z e^{\theta x} \qquad \sum p_i = 1 = \sum Z e^{\theta_i x} \qquad p_i = \frac{e^{\theta_i x}}{\sum e^{\theta_i x}}$$

$$\underbrace{Z = \frac{1}{\sum e^{\theta_i x}}}_{\text{это модель}}$$

softmax

потому что max недифференц. ф-ия, а эта дифференцируемая

теперь нужно сделать loss для этой ф-ии многоклассовой лог. регрессии

много классов теперь у нас

$$y = \{y\}_{l=1}^{K}$$

$$p = \{p_i\}_{i=1}^{K} \qquad P(y = y_i \mid x) = p_i$$

$$P(y = y \mid x) = \prod_{i=1}^{K} p_i^{y_i} \quad \Big| \log$$

потому что много классов и это типо switch

$= \sum_{i=1}^{K} \log(p_i^{y_i}) = \sum_{i=1}^{K} y_i \log(p_i^{y_i})$ | ∘ (−1) т.к. хотим minim. loss

cross энтропия (с −) в этой сумме всегда будет 1 слагаемое, но не всегда

если классы плохо разбиты, то может быть и не 1 значение, это делается для сглаживания

Мы говорим модели, что она может немного ошибиться

Дальше берём производную

$-\sum_{i=1}^{K} y_i \log(p_i) \Rightarrow$ пока выбросим всё то что не надо

нужно взять производную по θ_i и θ_j

$$\log(p_i) = \lg\left(\frac{e^{\theta_i x}}{\sum e^{\theta_j x}}\right)$$

$$\log\left(\frac{e^{\theta_i x}}{\sum e^{\theta_i x}}\right)_{\theta_i} = \lg(e^{\theta_i x}) - \lg\left(\sum e^{\theta_i x}\right) = \frac{e^{\theta_i x}}{e^{\theta_i x}} = X$$

$$x - \frac{1}{\sum e^{\theta_j x}} = x - \frac{x e^{\theta_i x}}{\sum e^{\theta_j x}} \Rightarrow x\left(1 - \frac{e^{\theta_i x}}{\sum e^{\theta_j x}}\right)$$

$$\log\left(\frac{e^{\theta_i x}}{\sum e^{\theta_j x}}\right)_{\theta_j,\, i \neq j} = \underset{\overset{\|}{0}}{\lg(e^{\theta_i x})} - \log\left(\sum e^{\theta_i x}\right)$$

$$\Rightarrow -\frac{1}{\sum e^{\theta_j x}} \cdot e^{\theta_j x} \cdot x$$

пр-ая cross entrop. для 1 переменной

$$\frac{\partial l}{\partial \theta_i} \Rightarrow \sum_{\substack{p=1 \\ l \neq i}}^{K} \frac{x e^{\theta_i x}}{\sum e^{\theta_j x}} y_p + y_i x \left(1 - \frac{e^{\theta_i x}}{\sum e^{\theta_j x}} \right)$$

$$\left(y_1 \log p_1 + y_2 \log p_2 + y_3 \log p_3 \right)'_{\theta_2}$$

тут будет $= 1$ слагаемое которое

$=$

= продолжаем упрощать

$$x\left(y_i - \sum \frac{e^{\theta_i x}}{\sum e^{\theta_j x}} \cdot y_l \right) \Leftarrow \left(\frac{\partial l}{\partial \theta} \right)$$

почти все из них 0

$$x\left(y_i - y_p \frac{e^{\theta_i x}}{\sum e^{\theta_j x}} \right) \uparrow$$

либо сколько не x вплотно до 1
либо сколько переброшено до 0,

$= x(y_i - p_i)$ т.к. $l = 1$ всегда

$=1$ т.к. только 1 единица может быть

$x(1 - p_i) \to$ если $y = 1$

$x(-p_i) \to$ если $y = 0$

Это мы посчитали по ∂x, теперь надо по всем и нужна сумма + среднее

θ-номер

$$\theta^{t+1} = \theta^t - \gamma \frac{\partial L}{\partial \theta} \quad x \cdot \left(y_i - y\,\frac{e^{\theta_i x}}{\sum e^{\theta_j x}}\right) =$$

$$x(y_i - p_i)$$

$$\frac{\partial L}{\partial \theta} = \frac{1}{N}\sum_{q=1}^{N} x_q (y_{q,i} - p_{q,i})$$

Мы придумали 2 модели

$$y = \theta x \qquad \theta x = y$$

$$y = \sigma(\theta x) \quad \theta x = \log\left(\frac{y}{1-y}\right)$$

$$y = f(\theta x) \quad \theta x = g(y)$$

обобщенные линейные модели

$$f(g(y)) = y$$

$$g(f(\theta x)) = \theta x$$

обычный лин рег предсказывает норм. р-е

лог. рег бернулли предсказывает бернулли

$y = e^{\theta x}$ $\theta x = \log(y)$ пуассона → это моделирует штуки, массовое

может быть пуассоновская регрес обслуживание

сии

Метрики

Accuracy – сколько раз совпало к общему объёму

$= \frac{1}{N} \sum (y_i == \hat{y}_i)$ ↙ большая K

balanced accuracy $= \frac{1}{K} \sum_{k=1}^{K} \frac{1}{|C_k|} \sum_{i \in C_k} (y_i == \hat{y}_i)$

presicion =

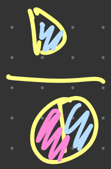

recall =

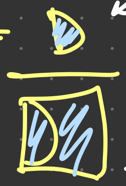

← кол-во угаданных

↖ на всех

Сколько 1 из всех которые 1 настоящее

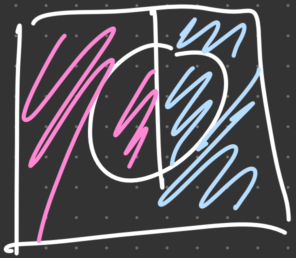

Сколько 1 из всех которые 1 мы угадали

$F_1 = \frac{2\,\text{precis} \cdot \text{recall}}{\text{pressicion} + \text{recall}}$

Есть roc auc кривая

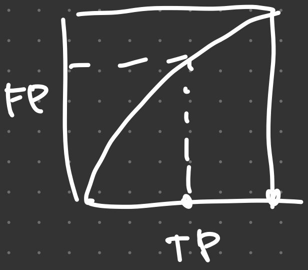

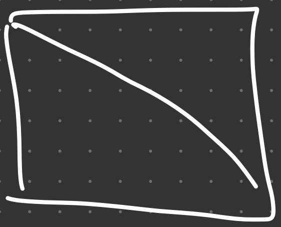

Если все выдаем 0, то TP=0, FP=0

ROC-AUC – это площадь под функцией

В идеале должен быть квадрат для бинарной классификации

говорит о том насколько наша модель объясняет классы