Введение в нат. обработку данных 28.08.26

Где брать данные?

Информация — это данные с чутью и НАН надо брать цвето инф-и для обр-и

1) Росстат (данные оф. статистики)
2) Спец. оборудование (датчики, наблюдение)
3) Из регистров и реестров (ручной сбор данных)

Сводка (выб-а из гсч статистика ?) сов-и) — наглядно-организац. обработка в материалах, данных, наблюдениях с помощью науч-ных методов по разработанной программе

Классиф-и, характеризуют (1 ур)

↓

Сводка (2 ур)

данные всегда нужно посмотреть в граф. виде (гистограмма, ...), то есть смотреть на что похоже

Нужно проанализировать и построить полярную гистограмму

Числовые характеристики:

① Абсолютные (объём исх данных)

② Относительные

③ Средние

Абсолютная величина

① N - объём; Размерность данных

② Относит → индекс (или индекс с динамики)

$$I = \text{Индекс} = \frac{\text{ХБ}}{\text{ХА}} = \frac{\text{относит / текущее (кого)}}{\text{базовое (с чем)}}$$

Нужно получить, на-р, индекс сравнения, индекс дома

Исходя из I, нужно найти темп

$$T = i - 1 \ (\%)$$

$T > 0 \rightarrow$ рост

$T < 0 \rightarrow$ спад

③ Средние

- $\bar{x} = \frac{\sum x_i}{N}$ ср. арифм

- $\bar{x} = \frac{\sum (x_i \cdot f_i)}{\sum f_i}$ средн. взвешенное

отличие → у вариационных более ср. ар. появилась частота

f_i → частота появления x_i в выборке

Свойства:

- $\frac{\sum (x_i + C)}{N} = \bar{x} + C$ увеличить на C каждый эл-т

- $\frac{\sum \frac{x_i}{C}}{N} = \frac{\bar{x}}{C}$ Уменьшить выборку на C

$C \neq 0 = const$

Для ранжир данных для дискретных (2 вариационных, 1 оч. малых, 1 – ограниченных и данные недискретно)

$[0 \cdot \infty]$ для сведения к одному разряду

Чтобы избежать погрешностей, нужно избегать куч делений с σ корней меньше ошибка

• Ср. квадратическое, кубическое

$$\overline{x^2} = \sqrt{\frac{\sum x_i^2}{N}} \qquad \overline{x^3} = \sqrt[3]{\frac{\sum x_i^3}{N}}$$

• Геометрическое Гармоническое

$$\overline{x} = \sqrt[N]{\prod_{i=1}^{N} x_i}$$

Удобно для проверок ср. величин

$$\overline{x}_{геом} \le \overline{x} \le \overline{x^2} \le \overline{x^3}$$

Упорядоченные данные (последовательность) — это ряд вариантов, ряд распределения

Ряд вариантов

↙ дискретный ↓ интервалы

Дискрет — зачем точные

Мало данных = до 30 данных!

Bootstrap размножить

Между дискреткой и интервалами можно сказать, делать так и так

$K = 1 + 1{,}44 \ln(N)$ — число интервалов, рекомендуемое

дискр

x_{min}

x_{max}



$$h(шаг) = \frac{x_{max} - x_{min}}{K}$$

При таком K — число не может быть целым, надо искать компромисс и можно n чуть подгонять

x_{min} — не может быть бесконечной дробью, в идеале целое,

если N $\to \infty$, то надо менять K

n, K → на них опираемся при разбиении данных

След. характеристика:
дисперсия, для содержательного описания она не годится

по опр-ю:

$$S^2 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{N}$$

$M(X)$ и $\bar{x}$ (мат. ожид.) | в статистике

$D(X)$ и S

⇒ поэтому σ как $M X$ в ф-ле

расчетная формула:

$$S^2 = \frac{\sum x_i^2}{N} - (\bar{x})^2$$

Неудобная
если тут отр. число
⇒ что-то посчитали
не так и нужно
потом себя ирод-ть.

$S = \sqrt{S^2}$

Средне. квадратическое

- Мода (Мо) – частота
- Медиана (Ме) – среднее в последовательности (для дискретных, для интервального построения)

могут значения на интервалах попасть

- Можно пользоваться правилом и добавляться в первую часть
- Можно по графику делить эти интервалы просят чуть подробнее посмотреть

Норм-распределение → проверка критерием

Персонд

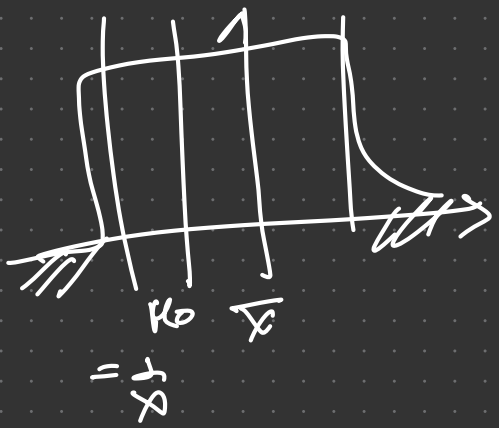
Исходя из нормального возникает

ассиметрия Персонда

$$A_s = \frac{\bar{x} - M_o}{S}$$

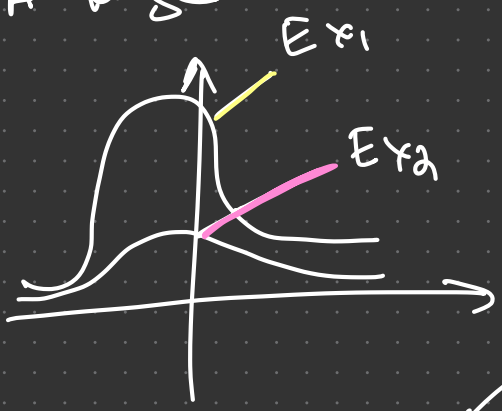
Куртозис

$$E_x =$$



$= \frac{1}{\bar{x}}$

В среднем пик в $\bar{x}$ (ср. ар), но каждый пик может совпадает с ядром на ядре



Кучизна:

$E_{x_1} > E_{x_2}$

A_3, E_x → показывают, насколько целесообразно проверять выборку на норм. распр-е

Да сказать не могут, но сказать нет могут

Доверительные интервалы — уровень уверенности не менее 0,9

$$\bar{x} - \left(t\right)\frac{S}{\sqrt{N}} \le \bar{x} \le \bar{x} + \left(t\right)\frac{S}{\sqrt{N}}$$

Ср. арифм. з-е очень важное на перспективу

Есть линейная и квадратичная корреляция

r – коэф. линейной корреляции

t – табличная величина из справочника

$t = (N, \alpha)$

Если обозначить выборку, то всегда можно посчитать ранее