Лог рег

1) Fit - поиск оптимальных весов } это лог рег
2) Predict - предсказания

- Для лог.рег мы будем более хитро комбинировать веса и признаки между собой
- будем использовать более экзотические функционалы потерь

Наша задача → выдать кредит или нет

данные → модель → да +1
↘ нет -1

То есть поставить метку класса

Обучить модель — значит найти оптимальные веса, которые будут минимизировать функционал потерь loss

min max scaler

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Числа получаются в диапазоне от 0 до 1 с сохранением относительных расстояний между значениями

Нужно, когда масштабы признаков сильно отличаются и это может затруднить оптимизацию градиентным спуском

↑ loss оказывается гораздо чувствительнее к изменениям одних весов, чем других

$x = [10, 20, 30, 40, 50]$

$x_1 = \frac{10-10}{50-10} = \frac{0}{\dots} = 0$; $x_2 = \frac{20-10}{40} = \frac{1}{4} = 0{,}2$

$x_3 = \frac{30-10}{40} = \frac{20}{40} = \frac{1}{2} = 0{,}5$; $x_4 = \frac{30}{40} =$

лог рег самый простой способ

$a(x) = \langle \theta, x \rangle$ → в лог рег предсказания строятся с помощью скалярного пр-я $\theta \cdot x$

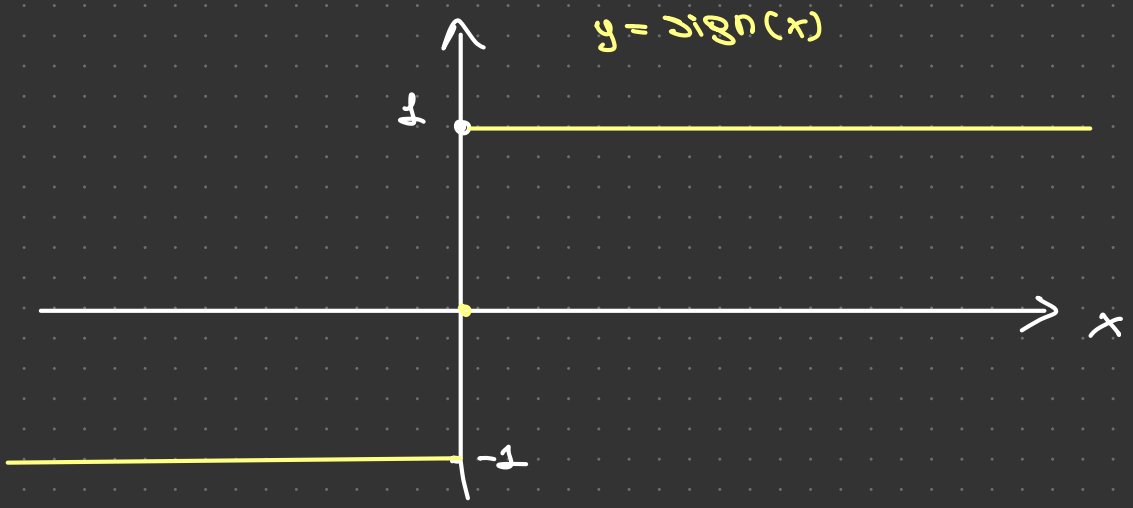
У нас уже есть оптимальный вектор весов θ

Допустим мы уже сделали предсказание и получили какое-то $\mathbb{R}$ число от $-\infty$ до $+\infty$.

Но мы хотели получить метку класса → -1 или $+1$

Для этого можно воспользоваться ф-ей sign

$$\text{sign}(x) = \begin{cases} 1, & x > 0 \\ 0, & x = 0 \\ -1, & x < 0 \end{cases}$$



Самый простой способ получить метод → применить ф-ию sign к вектору весов скалярно умноженный на вектор признаков

$$a(x) = \text{sign}(\langle \theta, x \rangle)$$

Поиск весов – loss()

Самый простой способ посчитать долю ошибок – это просто посчитать кол-во ошибок на общее кол-во наблюдений

И модель будет лучше, если доля ошибок меньше

$$L(f, X) = \frac{1}{N} \sum_{i=1}^{N} [f(x_i) \neq y_i]$$

$f(x_i)$ – предсказание

y_i – фактическое з-е

$[F(x_i) \neq y_i]$ → индикатор

↙ ↘

1 0

True False

Но есть проблема — значения −10 и −60000 для нашей модели эквивалентны

| $-10 \sim -10000$ |

Очевидно, что −10 и −10000 это разное

=> нужно смотреть не только на знаки, но и на значения M - margin, отступ

| $M_i = y_i \langle \theta, x_i \rangle$ |

y_i: 1 — реальное з-е

$\langle \theta, x_i \rangle$: ↓ предсказ

$\langle \theta, x \rangle$	y	$Margin$
Скалярное произведение	Факт	Отступ
0.2	+1	0.2

$M_i = +1 \times 0.2 > 0$

Если знак y_i совпадает с $\langle \theta, x \rangle$, то

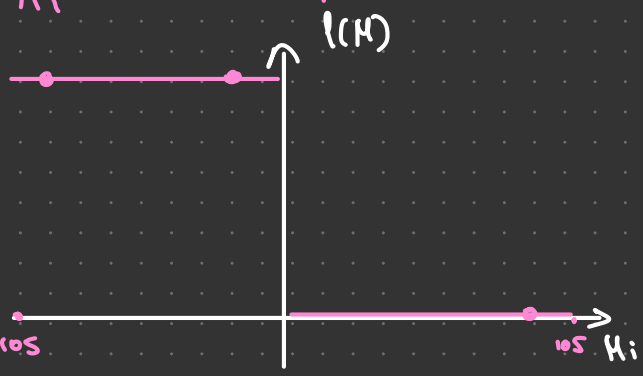
- $M_i \geq 0$ и нужно стараться сделать margin как можно больше
- $M_i < 0$ $M_i = +1 \times (-0.1) < 0$ => значит y_i и $\langle \theta, x \rangle$ разные по знаку и модель ошиблась

$$L(f, X) = \frac{1}{N} \sum_{i=1}^{N} [f(x_i) \neq y_i]$$

$$\Downarrow$$

$$\boxed{Q(f, X) = \frac{1}{N} \sum_{i=1}^{N} [\underbrace{y_i \langle \theta, x_i \rangle}_{M_i} < 0]}$$

loss с отступом



	$\langle w, x \rangle$	y	$Margin$
Заемщики	Скалярное произведение	Факт	Отступ
Иванов	-100	+1	-100
Петров	23	+1	23
Сидоров	12	-1	-12

$$P(M) = [\underbrace{y_i \langle \theta, x_i \rangle}_{M_i} < 0]$$

теперь есть ещё несколько проблем

- Мы взяли M и никак не используем это зн-е
- loss не гладкий, а град. сп. работают только на гладких ф-ях