1 лекция по ML

ML (обучение с учителем) — обучить алгоритм, позволяющий предсказывать целевую переменную

В общем виде, у нас есть:

loss функцию, которую мы всегда стараемся минимизировать

$$ML \sim \quad \theta^* = \underset{\theta}{\operatorname{argmin}}\ L(X, \theta)$$

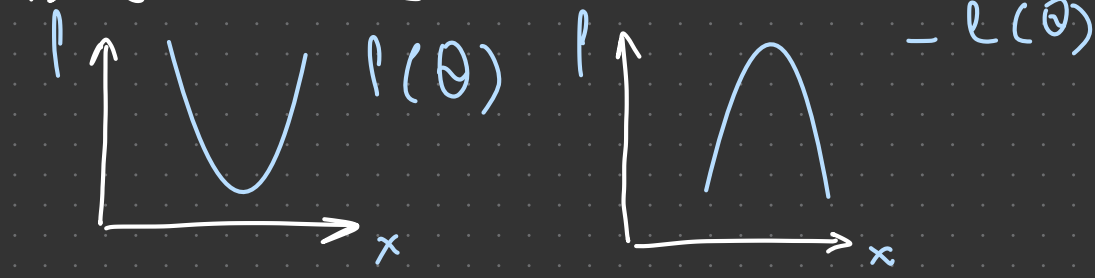
где:

- X – обучающие данные
- θ – веса, параметры модели
- $L(X, \theta)$ – ф-ия потерь, зависящая от X и θ
- $\arg\min$ – операция поиска $\min$ θ
- θ^* – найденные параметры

Максимизация ф-ии:

$$\arg\max_{\theta} L(X, \theta) = \arg\min_{\theta} [-L(\theta)]$$

то есть мы перевернем график функции loss вдоль оси



D-входные M-выходные.

Задачи ML:

1) Регрессия $F(X \to \mathbb{R}^m)\ \mathbb{R}^D \to \mathbb{R}^M$

2) Классификация $F(X \to C \subseteq N)$ или $X \to \{0,1 \dots K\}$

K-класс

...

Loss принимает на вход θ и X, возвращает $\mathbb{R}$ – одно число, величину ошибки

$$L : X \times \theta \to \mathbb{R}$$

Рассмотрим на квадрате ошибки

$$\hat{y} = \theta x$$

$$L(x, y, \theta) = (\theta x - y)^2$$

$x_i = 2,\ y_i = 6,\ \theta_i = 2 \Rightarrow L(2, 6, 2) = (2 \cdot 2 - 6)^2 = (-2)^2 = 4$

то есть функция берущая одно число → величину ошибки

Наша цель ML — найти такое отображение, которое лучше всего приближает истинное соответствие между объектами и target

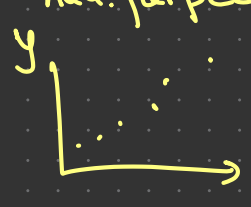
Отображение — это функция, которая сопоставляет элементам одного м-ва эл-ты другого. То есть по факту это модель, например, линейная

Регрессия — отображение из пространства признаков в пр-во действительных чисел

Линейные ф-ии $y = w_1 x_1 + \dots + w_D x_D + w_0$

- $w_1 \dots w_D, w_0$ – параметры θ
- $x_1 \dots x_D$ – вектор признаков feature
- y – target

Лин. регрессия – метод машинного обучения



Нужно построить аппроксимацию – это восстановление полной зависимости по кусочно заданной ф-ии

$$\sim y = \langle x, w \rangle + w_0$$

Нужно искать вектор $(w_0 \dots w_D) \in \mathbb{R}^{D+1}$

Линейная модель — когда она линейна по неизвестным признакам (для лин. рег)

- $y = w_1^2 x_1 + w_2 x_2 + w_0$ – нелинейная т.к. w_2^2
- $y = w_1 x_1^2 + w_2 x_2^2 + w_0$ – линейная, т.к. $z = x^2$

$$y = w_1 z_1 + w_2 z_2 + w_0$$

То есть если X зависит от нелинейной ф-ии, то мы всё ещё можем добавить новые спрятанные в регрессию и она будет линейной

$$y \sim w_1 x_1 + w_2 x_2 + w_3 \log x_3 + w_4 \operatorname{sign}(x_1 x_2) + w_0$$

По сути ML - это аппроксимирующая исходной ф-ии по точкам (классический ML)

inp → n наблюдений R^n

надо понять как взаимосвязаны точки, то есть наш рег - строит линейную аппроксимацию по исходным точкам

∃ $b = 0$ $\Rightarrow$ $y = w_1 x_1 + w_0$

One-hot encoding — если фича $\notin \mathbb{R}$, а является категориальным признаком, то её нужно будет закодировать

x_1 x_2 x_3 x_4

	weight	type_parrot	type_cat	type_dog	type_hamster	color_black	color_brown	color_gr
0	0,600	1	0	0	0	0	0	0
1	3,000	0	1	0	0	1	0	0
2	0,800	0	0	0	1	0	1	0
3	5,000	0	1	0	0	0	0	1
4	7,000	0	0	1	0	1	0	0

$x_1 + x_2 + x_3 + x_4 = 1$

Т.к из x_i можно выразить через остальные, то есть один столбец избыточен, x_4

$x_4 = 1 - x_2 - x_3 - x_1$

У нас модель со свободным членом

$$y = x_1 w_1 + w_2 x_2 + w_3 x_3 + w_0$$

тогда предсказания для x_1, x_2, x_3

1) $w_1 + w_0$
2) $w_2 + w_0$ $\Rightarrow$ остальные параметры зануляются
3) $w_3 + w_0$

∃ $(w_1, w_2, w_3, w_0) = (10, 20, 30, 5)$
$\Rightarrow$ y в зависимости от w $(15, 25, 35)$

Изменим все значения, включая w0 на 5

$J(w_1, w_2, w_3, w_0) = (5, 15, 25, 10)$

$\Rightarrow w(15, 25, 35) \rightarrow$

Тк. признаки зависимые у объекта активны 3 признака и из-за этого

1) Каждый найти единственный набор верных значений (это проблема для модели)

2) Веса зависят от их инициализации, а не напрямую от спуска

3) $X^T X$ оказывается необратимой

Удалили столбец для устранения линейной степени свободы

$$\hat{y} = w_1 x_1 + w_2 x_2 + w_0$$

Теперь выход однозначен

$$\begin{cases} w_1 + w_0 \\ w_2 + w_0 \\ w_0 \end{cases}$$

Необратимая матрица — для неё не существует обратной матрицы

Чуть более детальный вывод для one hot:

$y = w_1 x_1 + w_2 x_2 + w_3 x_3 + w_0$

$x_1 + x_2 + x_3 = 1$

$x_3 = 1 - x_2 - x_1$

$y = w_1 x_1 + w_2 x_2 + w_3 \cdot (1 - x_2 - x_1) + w_0$

$y = w_1 x_1 + w_2 x_2 + w_3 + w_3 x_2 + w_3 x_1 + w_0$

$y = w_1 x_1 + w_3 x_1 + w_2 x_2 + w_3 x_2 + w_3 + w_0$

$y = x_1 (w_1 + w_3) + x_2 \cdot (w_2 + w_3) + (w_3 + w_0)$

Мы избавились от x_3

$$\begin{cases} w_1 + w_3 = w_1' \\ w_2 + w_3 = w_2' \\ w_3 + w_0 = w_0' \end{cases} \Rightarrow y = w_1' x_1 + w_2' x_2 + w_0'$$

Общий вывод для K категорий

K категорий

$$\sum_{i=1}^{K} x_i = 1$$

$$x_K = 1 - \sum_{i=1}^{K-1} x_i$$

$$\hat{y} = \sum_{i=0}^{K-1} w_i x_i + w_K \cdot \left(1 - \sum_{i=1}^{K-1} x_i\right) + w_0$$

$x_1 + w_K -$

$$\hat{y} = w_1 x_1 + w_2 x_2 + w_3 + w_3 \cdot (1 - x_1 - x_2 - x_3) + w_0$$

$$\hat{y} = w_1 x_1 + w_2 x_2 + x_1 w_3 + x_2 w_3 + x_3 w_3 - w_3 + w_0$$

...

$$(w_1 - w_4) x_1 + (w_2 - w_4) x_2 + (w_3 - w_4) x_3 + w_0$$

Возвращаем знак суммы

$$\sum_{i=0}^{M-1} (w_i - w_M) \cdot x_i + (w_0 + w_M)$$

Мы хотим приблизить $f(x)$ к y

→ нужно уметь измерять качество модели

→ нужно уметь определять ошибку

loss F — функция потерь

Она должна быть гладкой, чтобы её легко можно было оптимизировать

Расстояние между предсказанным значением и реальным есть ошибка

Манхэттенская норма

L1-норма: — измеряет величину вектора

$w_1 = (3, 4)$

$$\|w\|_1 = \sum_{i=0}^{D} |w_i|$$

просто сумма модулей

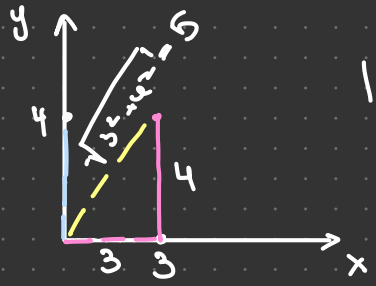
$\|(3,4)\|_1 = |3| + |4| = 7$

Евклидова норма

L2-норма — длина вектора по Пифагору

$$\|w\|_2 = \sqrt{\sum_{i=0}^{D} w_i^2}$$

кратчайшее расстояние от начала координат до конца вектора



$\|3,4\|_2 = 5$

$$\|x\|_p = \left(\sum_{i=1}^{|x|} |x_i|^p \right)^{\frac{1}{p}}$$

По правилу Δ : $a+b \geq c$ -> то если идти в обход мы должны дольше, чем напрямую

Это распространяется и на вектора — $\|x+y\| \leq |x|+|y|$

Подробнее про нормы будет в другом файле

$$L(F, X, y) = \|y - F(x)\|_2^2 =$$

$$= \|y - X \cdot w\|_2^2 = \sum_{i=1}^{N} (y_i - \langle x_i, w \rangle)^2$$

На выборках разного размера ошибка будет разной и не сравнимой => нужно нормализовать

$$MSE = L(F, X, y) = \frac{1}{N} \sum_{i=1}^{N} (y_i - \langle x_i, w_i \rangle)^2$$

MSE — функция потерь, среднеквадратичное отклонение

Разница с L_2 косметическая

$$\boxed{MSE = \frac{1}{N} \|y - Xw\|_2^2}$$

МНК — задаёт задачу оптимизации, найти веса при которых сумма квадратов ошибки min

$$w^* = \arg\min_w \|\hat{X}_w - y\|_2^2$$

МНК

Аналитическое

Вывод формулы

Град. спуск на 1 признаке

Численное

Пошаговый алгоритм численный

Градиентный спуск — один из методов численного решения

∃ $L(w)$ → loss, w - веса

$$w^* = \arg\min_w L(w)$$

Градиентный спуск рассматривается для ф-ии потерь

по определению производной

$$L'(w) = \lim_{\Delta w \to 0} \frac{L(w + \Delta w) - L(w)}{\Delta w}$$

– у из-я функции при небольшом изменении w

$L'(w) > 0$ – ф-ия растёт локально вправо ↗

$L'(w) < 0$ – функция убывает вправо ↙

$L'(w) = 0$ – стационарная точка, min/max или — другая стац. точка

$\Delta w = w_{новый} - w_{старый}$ то, насколько вес изменился

$= w_и = \Delta w + w_{стар.}$ просто величина изменения веса

Производная показывает, как локально изменяется значение ф-ии при изменении его аргумента

$l(1) = (1-3)^2 = 4$

$l(2) = (2-3)^2 = 1$

$l(3) = (3-3)^2 = 0$

$$l'(w) = \lim_{\Delta w \to 0} \frac{l(\Delta w + w) - l(w)}{\Delta w}$$

• $l(w+\Delta w) - l(w)$ => изменение ф-ии потерь → новая ошибка — старая

$$\frac{l(w+\Delta w) - l(w)}{\Delta w} \rightarrow$$ на сколько изменилась ошибка на единицу изменения веса

$\Delta w \to 0$ рассматриваем все меньшие изменения веса чтобы узнать производную в точке

Производная связана с направлением движения

$L'(w) > 0$, значит при ↑ веса ошибка ↑ → нужно w уменьшать

$l'(w) < 0$, значит при ↑ веса ошибка уменьшается => нужно w увеличить

$l'(w) = 0$ min/max/стац. точка, вес на текущем при ↑

Пример:

$l(w) = (w-3)^2$

$l'(w) = 2(w-3)$, $w=1$ → $l'(1) = 2 \cdot (-2) = -4$

⇒ нужно ↑ w для ↓ ошибки

Получим изменение ф-ии из определения производной

$$l(w) = \lim_{\Delta w \to 0} \frac{l(w+\Delta w) - l(w)}{\Delta w}$$

при $\Delta w \to 0$, то отношение близко к производной и lim можно опустить

lim не утверждает, что при ∀ маленьком Δw отношение точно = производной,
оно лишь утверждает, что его можно сделать сколь угодно близким к производной, выбирая маленькое Δw

Пример:

$l(w) = w^2$, $w=3$

$$l'(w) = \lim_{\Delta w \to 0} \frac{l(3+\Delta w) - l(3)}{\Delta w} \approx$$

$$l'(w) = \lim_{\Delta w \to 0} \frac{(3+\Delta w)^2 - 3^2}{\Delta w}$$

Раскроем

$$f'(w) = \lim_{\Delta w \to 0} \frac{9 + 6 \cdot \Delta w + \Delta w^2 - 9}{\Delta w} \Rightarrow$$

$$f'(w) = \lim_{\Delta w \to 0} \frac{6\Delta w + \Delta w^2}{\Delta w} = \frac{\Delta w\,(6 + \Delta w)}{\Delta w} =$$

$\lim_{\Delta w \to 0} 6 + \Delta w$ вычислим $\lim = \lim 6 + 0 = 6$

$\Rightarrow f'(w) = 6$

Посмотрим на приближение

$$\frac{f(3+\Delta w) - f(3)}{\Delta w} = 6 + \Delta w$$

Рассмотрим Δw

$\Delta w = 1 \Rightarrow 6 + 1 = 7$

$\Delta w = 0{,}1 \Rightarrow 6 + 0{,}1 = 6{,}1$

$\Delta w = 0{,}01 \Rightarrow 6{,}01$

...

Чем больше $\Delta w \to 0$, тем ближе к 6 значение

$\Rightarrow$ мы имеем право написать вот так

$$L'(w) \approx \frac{L(w + \Delta w) - L(w)}{\Delta w}$$

$\cdot \Delta w \Rightarrow$ $f'(w) \cdot \Delta w \approx f(w + \Delta w) - f(w)$

$$L(w + \Delta w) \approx f(w) + f'(w) \cdot \Delta w$$

Новая ошибка = старая ошибка + изменение ошибки

Выбор Δw чтобы ошибка уменьшалась:

$l(w+\Delta w) < l(w)$ $\quad l(w)$ – тут это прошлая ошибка

Из предыдущей формулы мы знаем, что

$$l(w+\Delta w) \approx l(w) + l'(w) \cdot \Delta w$$

Чтобы право стало < надо $l'(w) \cdot \Delta w < 0$

=> производная и изменение веса должны иметь противоположные знаки

- $l'(w) = 4 \Rightarrow \Delta w = -0{,}1 \Rightarrow$ пр-е отриц.
- $l'(w) = -4 \Rightarrow \Delta w = 0{,}1 \Rightarrow$ пр-е отриц.

Чтобы вручную не выбирать знаки есть правило

$$\Delta w = -\alpha\, l'(w)$$

$\alpha > 0$, – это шаг обучения

α помогает управлять размером изменения веса

Подставим его в приближенную формулу:

$$l'(w+\Delta w) \approx l(w) + l'(w) \cdot (-\alpha \cdot l'(w))$$

$$l'(w+\Delta w) \approx l(w) - \alpha \cdot l'(w) \cdot l'(w)$$

$$l'(w+\Delta w) \approx l(w) - \alpha \cdot l'(w)^2$$

$l'(w)^2 \geq 0$, $\alpha > 0 \Rightarrow \alpha \cdot l'(w)^2 > 0$

=> при нулевой производной и достаточно маленьком шаге ошибка будет уменьшаться.
=> доказано, что двигаясь в производной вниз мы ошибку

Теперь можно получить формулу град. спуска

$$w_{новый} = w_{старый} + \Delta w \qquad \Delta w = -\alpha \cdot l'(w)$$

$$w_{новый} = w_{стар} - \alpha \cdot L'(w)$$

$$\theta_{t+1} = \theta - \alpha \cdot l'(w)$$ → это и есть формула град спуска

Рассмотрим на конкретном примере

$l(w) = w^2$

] Мы в точке $w = 3$

$$\lim_{\Delta w \to 0} \frac{l(3+\Delta w) - l(3)}{\Delta w}$$ посчитаем $l'(w)$, производную ф-ии потерь

$$\frac{(3+\Delta w)^2 - 3^2}{\Delta w} = \frac{9 + 6\Delta w - \Delta w^2 - 9}{\Delta w}$$

$$= \frac{6\Delta w + \Delta w^2}{\Delta w} = \frac{\Delta w\,(6 + \Delta w)}{\Delta w} = 6 - \Delta w$$

$$l'(w) = \lim_{\Delta w \to 0} 6 + \Delta w \Rightarrow \approx 6$$

производная положительная, при $\uparrow w$ ф-ия ошибки будет расти

Мы получили производную, теперь можем использовать её чтобы обновить вес в градиентном спуске

Нужно получить формулу новой точки

$$l'(w) = \lim_{\Delta w \to 0} \frac{l(w + \Delta w) - l(w)}{\Delta w} \Rightarrow$$

↓ нужно найти $l(w + \Delta w)$ $\Delta w = w_{нов} - w_{стар}$ т.к. это новое зн-е

$$l'(w) \approx \frac{l(w + \Delta w) - l(w)}{\Delta w} \quad | \cdot \Delta w$$

$$l'(w) \cdot \Delta w \approx l(w + \Delta w) - l(w)$$

$$l(w + \Delta w) = l(w) + l'(w) \cdot \Delta w$$ мы ↓ ошибку $\Rightarrow$

$l'(w) \cdot \Delta w < 0$

мы хотим $l(w + \Delta w) < l(w)$

$\exists\ \Delta w = -\alpha \cdot l'(w) \Rightarrow$ мы идём в противоположную сторону градиента на шаг α

Подставим

$$f(w + \Delta w) = f(w) + f'(w) \cdot (-\alpha \cdot f'(w))$$

$$f(w + \Delta w) = f(w) - \alpha \cdot f'w^2$$

т.к мы всегда уверены что $\alpha \cdot f'w^2 > 0$ => уменьшение скаляра

мы доказали что можно использовать $-\alpha f'(w)$

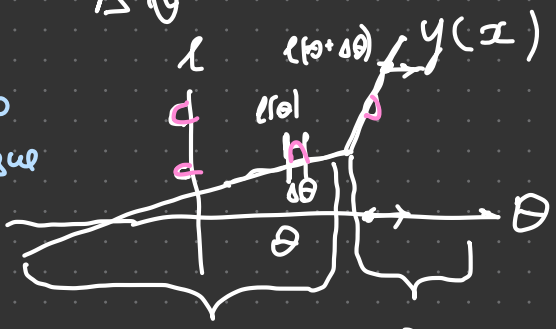
Теперь осталось подставить его в формулу определения нового веса

$$\theta^* = \arg\min_{\theta} l(\theta) \qquad l(\theta) = \|y - x\theta\|_2^2$$

$$l'(\theta) = \lim_{\Delta\theta \to 0} \frac{l(\theta + \Delta\theta) - l(\theta)}{\Delta\theta}$$

1	3
0,1	0,1

Насколько сильно возрастёт функция при изменении аргумента ($\Delta\theta \to 0$) довольно напишем



$$l'(\theta) \approx \frac{l(\theta + \Delta\theta) - l(\theta)}{\Delta\theta} \Big| \cdot \Delta\theta$$

$$\Delta\theta\, l'(\theta) = l(\theta + \Delta\theta) - l(\theta)$$

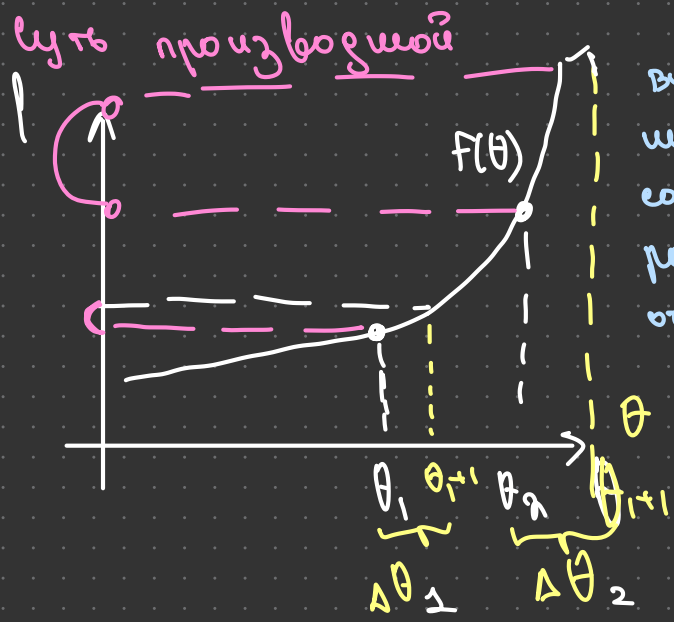
$$l(\theta + \Delta\theta) = l(\theta) + \Delta\theta\, l'(\theta) \qquad \Delta\theta = -\alpha \cdot l'(\theta)$$

$$l(\theta + \Delta\theta) = l(\theta) + l'(\theta) \cdot (-\alpha \cdot l'(\theta))$$

$$l(\theta + \Delta\theta) = l(\theta) - \alpha \cdot l'(\theta)^2 \Rightarrow \Delta\theta = -\alpha \cdot l'(\theta)$$

$$\leq 0$$

$$\theta_{t+1} = \theta_t + \Delta\theta \Rightarrow \theta_{t+1} = \theta_t - \alpha \cdot l'(\theta)$$



Видно, что при изменении шага на $d = 1$, loss совсем по разному растёт в зависимости от скорости роста ф-ии

То есть производная показывает насколько изменилось зн-е функции между точкой и её приращением относительно самого приращения

Из графика видно, что:

$\Delta\theta = \theta_{новое} - \theta_{старое}$ => то есть это разница

Очевидно что $\Delta\theta_1 < \Delta\theta_2$ т.к. loss тут быстро растёт

Градиентный спуск на множестве признаков

Пусть $\hat{y} = \theta_1 x_1 + \theta_2 x_2$

Всю можно объединить в вектор

$\theta = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}$ и ф-ия будет зависеть сразу от 2х переменных

$L = (\theta_1, \theta_2)$ нужно уменьшить оба веса чтобы ↓ ошибку

Из прошлых выводов мы получили:

$$\theta_{t+1} = \theta_t - \alpha \cdot L'(\theta)_t$$

Т.к. $n > 1$, теперь ошибка зависит от двух переменных

Пусть $L(\theta_1, \theta_2) = \theta_1^2 + 2\theta_2^2$ min в (0,0)

Берём частную производную по θ_1

Пусть $h \to$ это изменение θ_1 относительно нового веса

$L(\theta_1, \theta_n) = L(\theta_1$

$F(g(x))' =$

$F'(g(x)) \cdot g'(x)$

Частная производная → мы хотим смотреть изменение только по 1ой переменной и фиксируем остальные

$$l(\theta_1) = \frac{l(\theta_1 + \Delta\theta_1) - l(\theta)}{\Delta\theta_1}$$

Если $l(\theta_1, \theta_2)$, мы сначала хотим понять, как изменение θ_1 влияет на loss, значит

$\theta_1 \to \theta_1 + h$ — h небольшое изменение
$\theta_2 \to \theta_2$

Получаем новый loss:

$l(\theta_1 + h, \theta_2)$

старый loss:

$l(\theta_1, \theta_2)$ => их разность будет приращением ф-ии потерь

$\to l(\theta_1 + h, \theta_2) - l(\theta_1, \theta_2)$

=> поделим её на h чтобы узнать среднюю скорость изменения ф-ии по θ_1

$$\frac{l(\theta_1+h,\theta_2)-l(\theta_1,\theta_2)}{h}$$

Вычислим частную производную через предел

$$\frac{\partial l}{\partial \theta_1}(\theta_1,\theta_2)=\lim_{h\to 0}\frac{L(\theta_1+h,\theta_2)-l(\theta_1,\theta_2)}{h}$$

↑ Это и есть определение частной пр-ой

Попробуем вычислить её через предел

$$\frac{\partial L}{\partial \theta_1}(\theta_1,\theta_2)=\lim_{h\to 0}\frac{l(\theta_1+h,\theta_2)-l(\theta_1,\theta_2)}{h}$$

$$l(\theta_1,\theta_2)=\theta_1^2+2\theta_2^2 \Rightarrow$$

$$\Rightarrow \lim_{h\to 0}\frac{(\theta_1+h^2)+2\theta_2^2-(\theta_1^2+2\theta_2^2)}{h}$$

$$\Rightarrow \lim_{h\to 0}\frac{2\theta_1 h+h^2}{h}\Rightarrow\frac{h(2\theta_1+h)}{h}$$ при $h\to 0$

$$\lim_{h\to 0} 2\theta_1+h \Rightarrow \frac{\partial l}{\partial \theta_1}=2\theta_1$$

По второй переменной мы выше сделали производную также

получится $\frac{\partial L}{\partial \theta_2} = 4\theta_2$

Теперь можем записать их в один вектор

$$\nabla l(\theta) = \begin{pmatrix} 2\theta_1 \\ 4\theta_2 \end{pmatrix}$$

И теперь вместо производной loss можно использовать градиент

$$\theta_{t+1} = \theta_t - \alpha \cdot \nabla L(\theta_t)$$ формула обновления весов

Далее мы должны выбрать то, как у нас может выглядеть loss - функция, допустим мы возьмём MSE через L_2- норму

$$L(\theta) = \frac{1}{N} \| \hat{y} - y \|_2^2 \quad | \; ^2$$ и раскроем норму

$$L(\theta) = \frac{1}{N} \cdot \sum_{i=0}^{N} (\hat{y} - y)^2 \quad | \; \hat{y} = \theta \cdot X$$

У нас один признак θ

$$l(\theta) = \frac{1}{N} \cdot \sum_{i=0}^{N} (\theta x_i - y_i)^2 \qquad \hat{y} = \theta \cdot x_i$$

$$\frac{\partial l}{\partial \theta} \left[\frac{1}{N} \cdot \sum_{i=0}^{N} (\theta x_i - y_i)^2 \right]$$

$$\frac{1}{N} \lim_{i=0}^{N} \left(\frac{\partial l}{\partial \theta} (\theta x_i - y_i)^2 \right)$$

берем производную сложной ф-ии

$$f(g(x)) = f'(g(x)) \cdot g'(x)$$

1) $\left((\theta x_i - y_i)^2\right)' \Rightarrow \underbrace{2 \cdot (\theta x_i - y_i)}_{f'(g(x))} \cdot \underbrace{x_i}_{g'(x)}$ x, y - const

$$\frac{\partial l}{\partial \theta} (\theta x_i - y_i)^2 = 2 (\theta x_i - y_i) \cdot x_i$$

$$\frac{\partial l}{\partial \theta} = \frac{1}{N} \cdot \sum_{i=0}^{N} 2 \cdot (\theta x_i - y_i) \cdot x_i$$

$$\frac{\partial l}{\partial \theta} = \frac{2}{N} \sum_{i=0}^{N} x_i (\theta x_i - y_i)$$

Производная MSE по одному весу

Подставим её в градиентный спуск

$$\theta_{t+1} = \theta_t - \alpha \cdot l'(\theta)$$

$$\theta_{t+1} = \theta_t - \alpha \cdot \left(\frac{2}{N} \sum_{i=0}^{N} x_i (\theta x_i - y_i) \right)$$

$$\theta_{t+1} = \theta_t - \frac{2\alpha}{N} \sum_{i=0}^{N} x_i (\theta x_i - y_i)$$

Градиентный спуск для MSE ошибки с одним параметром

Но если у нас несколько признаков?

тогда $\hat{y} = \sum_{i=0}^{D} \theta_i x_i$

Для каждого веса нужно получить частную производную

$$\frac{\partial l}{\partial \theta_i} = \frac{2}{N} \cdot \sum_{i=0}^{N} x_{ij} (\hat{y}_i - y_i)$$

Далее рассмотрим на примере конкретной матрицы

$$X = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}$$

$$X = \begin{matrix} x_1 & x_2 \end{matrix} \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix} \quad N \times D$$

$$\theta = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} \quad D \times 1$$

$$y = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} \quad N \times 1$$

X – матрица признаков
θ – вектор весов
y – реальные зн-я
N – кол-во объектов
D – кол-во признаков

$$\hat{y} = X \cdot \theta$$

$$\begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix} \cdot \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}$$

Расмотрим матричное пр-е

$$\begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = \begin{pmatrix} 1 \cdot \theta_1 + 2 \cdot \theta_2 \\ 3\ \theta_1 + 4 \cdot \theta_2 \\ 5 \cdot \theta_1 + 6 \cdot \theta_2 \end{pmatrix} \Rightarrow \hat{y}_i = \sum_{j=1}^{D} x_{ij} \cdot \theta_j$$

Предсказание для объекта в общем виде

Вычислим ошибку предсказаний

$$e_i = \hat{y}_i - y_i$$

$e = X\theta - y$ для всех объектов

Рассмотрим матрично

$$\begin{pmatrix} e_1 \\ e_2 \\ e_3 \end{pmatrix} = \begin{pmatrix} \hat{y}_1 - y_1 \\ \hat{y}_2 - y_2 \\ \hat{y}_3 - y_3 \end{pmatrix}$$

$$\hat{y} = X\theta = e_i + y_i$$

$$\Rightarrow e_i = \hat{y} - y_i$$

Вычислим MSE

$$l(\theta) = \frac{1}{N} \sum_{i=0}^{N} (\hat{y}_i - y_i)^2$$

$$l(\theta) = \frac{1}{N} \sum_{i=0}^{N} e_i^2$$

по l_2- норме $\|x\|_2 = \sqrt{\sum_{i=0}^{\|x\|} e_i^2} \Rightarrow \|x\|_2^2 = \sum_{i=0}^{\|x\|} e_i^2$

$$l(\theta) = \frac{1}{N}\sqrt{\sum_{i=0}^{N} e_i^2} = \frac{1}{N}\|e_i\|_2$$

т.к. $\hat{y} = X \cdot \theta$ а $e_i = \hat{y} - y_i$

$$e_i = x_i\theta - y_i$$

$$l(\theta) = \frac{1}{N}\|X\theta - y\|_2^2$$

эту функцию мы хотим минимизировать

! X и y - фик. данные, const

найдём частную производную loss по каждому θ

$$l(w) = \frac{1}{N}\sum_{i=0}^{N}\left(\sum_{k=0}^{D} x_{ik}\theta_i - y_i\right)^2$$

Смотрим как меняется производная при изменении одного веса

$$\frac{\partial l}{\partial \theta_j} = \frac{\partial e}{\partial \theta_j}\left[\frac{1}{N}\sum_{i=0}^{N}\left(\sum_{k=0}^{D} x_{ik}\theta_i - y_i\right)^2\right]$$

$$\Rightarrow \frac{1}{N}\cdot\frac{\delta l}{\delta \theta_j}\left[\sum_{i=0}^{N}\left(\sum_{k=0}^{D} x_{ik}\theta_i - y_i\right)^2\right]$$

т.к. производная суммы = сумме производных

$$\frac{1}{N} \cdot \left[\sum_{i=0}^{N} \frac{6l}{6\theta_j} \left(\sum_{k=0}^{D} x_{ik}\theta_k - y_i \right)^2 \right]$$

$g(x)$

$F(g(x))$

$$g_i(w) = \sum_{k=1}^{D} (x_{ik}\theta_k - y_i)^2$$

$$\frac{\partial L}{\partial \theta_j} (g_i(\theta))^2 = 2 \cdot g_i(\theta) \cdot \frac{\partial g_i(w)}{6\theta} =$$

$g_i'(\theta) = x_{i1}\theta_1 + x_{i2}\theta_2 + \dots + \dots$ т.к. x и θ — const

$$\frac{\partial}{\partial \theta_j} (g_i(\theta_j)) = x_{ij}$$? почему

$$\frac{\partial l}{\partial \theta_j} = \frac{1}{N} \sum_{i=1}^{N} 2\, g_i(\theta)\, x_{ij}$$

т.к. $g_i(w) = g_i - y = e$

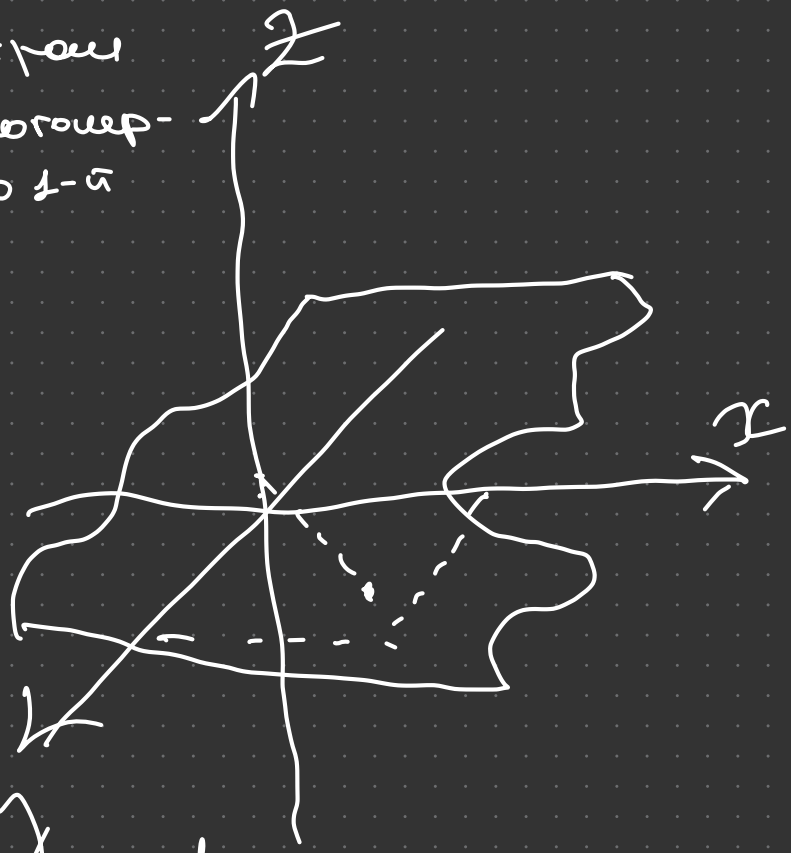
$$\frac{\partial l}{\partial \theta_j} = \frac{1}{N} \sum_{i=1}^{N} x_{ij} e_i$$

Частная пр-я MSE по конкретному весу

Чтч. пр-ая считается по параметрам

это пр-ие многомер-ной ор-ии по t-й переменной

ϕ_t





← параметров

